

Proyecto Final – Entrega 1



**UNIVERSIDAD
DE ANTIOQUIA**

1 8 0 3

Por: Sebastian López Gómez
CC. 1026152258

Profesor: Dr. Raúl Ramos Pollán

Maestría en Ingeniería
Departamento de Ingeniería
Universidad de Antioquia
Medellín, 2023-2

Contexto

La detección de defectos, como perforaciones, líneas de soldadura y manchas de aceite sobre superficies metálicas encuentra su aplicación principal en la industria manufacturera y metalmecánica. En este contexto, el conjunto de datos GC10-DET disponible en la plataforma Kaggle, cuyos datos fueron recopilados en un entorno industrial real, se presenta como una valiosa fuente de información para el entrenamiento de un modelo de detección. Este comprende diez distintos tipos de defectos superficiales comúnmente encontrados en láminas metálicas. Desde perforaciones no deseadas hasta irregularidades en la soldadura, este conjunto de datos proporciona una representación amplia de los desafíos que enfrenta la industria en términos de control de calidad.

La implementación del modelo a desarrollar facilita una evaluación rápida y objetiva de la calidad de los productos, lo que conduce a la reducción de tiempos de inspección en comparación con métodos manuales y, en última instancia, a una mayor eficiencia en la línea de producción. Además, al detectar defectos con precisión, el modelo contribuye directamente a la optimización de las operaciones de mantenimiento, permitiendo tomar decisiones informadas sobre reparaciones o reemplazos inmediatos, lo que resulta en una reducción de costos asociados con el mantenimiento preventivo y correctivo, mientras se asegura un nivel óptimo de calidad en los productos finales.

Objetivo

Detectar 10 tipos diferentes de defectos sobre una superficie metálica, dado un conjunto de entrenamiento de imágenes.

Dataset

El Dataset GC10-DET (<https://www.kaggle.com/datasets/zhangyunsheng/defects-class-and-location>) contiene imágenes de diferentes defectos sobre la superficie de una lámina de acero, cuyas etiquetas de clase se encuentran en subcarpetas, así:

1. 'inclusion'
2. 'waist folding'
3. 'rolled_pit'
4. 'oil_spot'
5. 'crescent_gap'
6. 'crease'
7. 'water_spot'
8. 'punching_hole'
9. 'silk_spot'
10. 'welding_line'

Esta base de datos proporciona 3570 imágenes, pesando 967,81MB en total. Cada imagen está en escala de grises y formato .jpg, con un tamaño de 2048x1000 píxeles.

Las anotaciones proporcionadas para cada imagen tienen la siguiente estructura

```
<annotation>
  <folder>6</folder>
  <filename>img_01_3436815300_00477.jpg</filename>
  <path>E:\002_Data\suface dectect\2-
fuxinzhe\msos1\6\img_01_3436815300_00477.jpg</path>
  <source>
    <database>Unknown</database>
  </source>
  <size>
    <width>2048</width>
    <height>1000</height>
    <depth>1</depth>
  </size>
  <segmented>0</segmented>
  <object>
    <name>6_siban</name>
    <pose>Unspecified</pose>
    <truncated>0</truncated>
    <difficult>0</difficult>
    <bndbox>
      <xmin>788</xmin>
      <ymin>13</ymin>
      <xmax>1367</xmax>
      <ymax>984</ymax>
    </bndbox>
  </object>
</annotation>
```

Estas anotaciones incluyen información como: nombre del archivo de la imagen, dimensiones de la imagen: ancho, alto y profundidad (1 por ser en escala de grises), y coordenadas xmax e ymax que indican el cuadro que delimita el objeto.

Métricas de Desempeño

- El **Recall** es una de las métricas utilizadas para evaluar el rendimiento de un modelo de detección. Mide la capacidad del modelo para identificar correctamente todas las instancias relevantes de una clase en particular. En el contexto de la detección de defectos en la superficie metálica, el Recall se refiere a la capacidad del modelo para detectar y clasificar

correctamente todos los casos de defectos en la superficie. Un alto Recall indica que el modelo es efectivo en la identificación de defectos, mientras que un recuerdo bajo sugiere que el modelo puede estar faltando algunos defectos.

- Otra métrica es el **AP** (Precisión promedio), esta se usa comúnmente en tareas de detección de objetos, incluida la detección de defectos de superficie. Mide la precisión promedio de un modelo en la detección de objetos de interés en diferentes niveles de precisión. Cuanto mayor sea el AP, mejor será el rendimiento del modelo en la detección precisa de defectos.
- En términos de rendimiento empresarial, un modelo de detección de fallas en este conjunto de datos permite supervisar la calidad de los productos industriales, garantizando que cumplan con los estándares de calidad previamente establecidos.

Referencias y Resultados Previos

El GC10-DET fue publicado en el año 2020, ha tenido poco más de 34 mil vistas y ha sido descargado un 10% de las veces que es visitado. En Kaggle están disponibles 4 notebooks que disponen del dataset tanto para análisis exploratorio de los datos, como para el desarrollo de modelos de detección y clasificación de defectos.

Esta base de datos proviene del artículo “Deep Metallic Surface Defect Detection: The New Benchmark and Detection Network” (Xiaoming et al, 2020), cuyo principal objetivo es proponer una red de detección end to end basada en el detector Multibox de Single Shot que permita optimizar la precisión y eficiencia de la detección de defectos en entornos industriales. En este artículo realizan un benchmarking para evaluar la efectividad del dataset propuesto con respecto a dos datasets diferentes: el NEU Surface Defect Dataset, y el SSD dataset. Realizan la comparación del método propuesto con otros métodos basados en deep learning, como Support Vector Machine SVM, sin embargo, su método con Deep Convolutional Networks resultó superar a los demás en su desempeño.

Uno de los artículos referenciados por la base de datos es “SSD: Single Shot MultiBox Detector”, tomado de la conferencia “Computer Vision – ECCV 2016”, en esta se presenta el Detector SSD (Single Shot MultiBox) una técnica de detección de objetos que simplifica el proceso al predecir tanto las cajas delimitadoras como las categorías de objetos en una sola pasada de red neuronal. Este enfoque elimina la necesidad de generar propuestas de objetos previamente y etapas posteriores de muestreo. Un ejemplo de su funcionamiento mostró que alcanza un 74,3% de Precisión Media (mAP) en la prueba VOC2007 con una entrada de 300x300 a 59 FPS y un 76,9% de mAP con entrada de 512x512, superando a modelos como Faster R-CNN.